

Формулы для обучения и инференса моделей

Если (x, t_x, n) - история активности пользователя, то можно выписать его правдоподобие по p и θ в контексте **BdW / BB** модели:

$$\begin{aligned} L(p, \theta, c|x, t_x, n) &= p(x, t_x, n|p, \theta, c) = \\ &= p^x(1-p)^{n-x}(1-\theta)^{n^c} + \sum_{i=0}^{n-t_x-1} p^x(1-p)^{t_x-x+i} \left((1-\theta)^{(t_x+i)^c} - (1-\theta)^{(t_x+i+1)^c} \right) \end{aligned} \quad (1)$$

Тогда $L(w, c|x, t_x, n)$ получается взятием ожидания (1) по q_w , где w -параметры распределения $(p, \theta) \sim q_w(p, \theta)$:

$$\begin{aligned} L(w, c|x, t_x, n) &= p(x, t_x, n|w, c) = \int p(x, t_x, n, p, \theta|w, c) dp d\theta = \\ &= \int p(x, t_x, n|p, \theta, c) p(p, \theta|w) dp d\theta = \\ &= \int L(p, \theta, c|x, t_x, n) q_w(p, \theta) dp d\theta \end{aligned} \quad (2)$$

В случае **BdW/BB** модели, где $w = (\alpha, \beta, \gamma, \delta)$, а $q_w(p, \theta) = B(p|\alpha, \beta)B(\theta|\gamma, \delta)$, (2) выражается явно:

$$\begin{aligned} L(\alpha, \beta, \gamma, \delta, c|x, t_x, n) &= \frac{B(\alpha + x, \beta + n - x)}{B(\alpha, \beta)} \frac{B(\gamma, \delta + n^c)}{B(\gamma, \delta)} + \\ &+ \sum_{i=0}^{n-t_x-1} \frac{B(\alpha + x, \beta + t_x - x + i)}{B(\alpha, \beta)} \left(\frac{B(\gamma, \delta + (t_x + i)^c)}{B(\gamma, \delta)} - \frac{B(\gamma, \delta + (t_x + i + 1)^c)}{B(\gamma, \delta)} \right) \end{aligned}$$

В случае **S_{BB}-G/B** модели и аналогичных у нас нет замкнутой формулы для вычисления, но мы можем считать правдоподобие методом Монте-Карло.

Пусть R_t - событие возвращения пользователя на t -ый период ($t > n$), а A_t - пользователь жив в t -ый период. Тогда

$$\begin{aligned} p(R_t|x, t_x, n, p, \theta, c) &= p(R_t|p, \theta, c) \frac{p(x, t_x, n|R_t, p, \theta, c)}{p(x, t_x, n|p, \theta, c)} \\ &= p(R_t|p, \theta, c) \frac{p(x, t_x, n|A_n, p)}{L(p, \theta, c|x, t_x, n)} \end{aligned} \quad (3)$$

(второе равенство следует из свойств вероятностного процесса индивидуального пользователя)

где

$$p(R_t|p, \theta, c) = p(1 - \theta)^{t^c}$$

$$p(x, t_x, n|A_n, p) = p^x(1 - p)^{n-x}$$

Тогда, чтобы получить $p(R_t|x, t_x, n, w, c)$ нужно взять ожидание (3) по

$$q(p, \theta|x, t_x, n, w, c) = \frac{p(x, t_x, n|p, \theta, c)}{p(x, t_x, n|w, c)} q_w(p, \theta) =$$

$$= \frac{L(p, \theta, c|x, t_x, n)}{L(w, c|x, t_x, n)} q_w(p, \theta)$$

Итого получаем формулу:

$$p(R_t|x, t_x, n, w, c) =$$

$$= L(w, c|x, t_x, n)^{-1} \int p(R_t|p, \theta, c) p(x, t_x, n|A_n, p) q_w(p, \theta) dp d\theta$$

В случае **BdW/BB** модели получаем:

$$p(R_t|x, t_x, n, \alpha, \beta, \gamma, \delta, c) =$$

$$= L(\alpha, \beta, \gamma, \delta, c|x, t_x, n)^{-1} \frac{B(\alpha + x + 1, \beta + n - x)}{B(\alpha, \beta)} \frac{B(\gamma, \delta + t^c)}{B(\gamma, \delta)}$$

Опять же в случае **S_{BB}-G/B** модели и аналогичных у нас нет замкнутой формулы для вычисления, но мы можем считать эту вероятность методом Монте-Карло.

Также имеем в общем виде и в случае для **BdW/BB** модели формулу Retention:

$$p(R_t|w, c) = \int p(1 - \theta)^{t^c} q_w(p, \theta) dp d\theta =$$

$$= \frac{\alpha}{\alpha + \beta} \frac{B(\gamma, \delta + t^c)}{B(\gamma, \delta)}$$